

1. 什么是ROC / AUC?

	真实类别 1	真实类别 0
预测类别 1	TP 真阳	FP 伪阳
预测类别 0	FN 伪阴	TN 真阴

- $TPRate = \frac{TP}{TP+FN}$  （真实为1的数据，我预测为1的比例， 也就是召回率）
- $FPRate = \frac{FP}{FP+TN}$  （真实为0的数据，我预测为1的比例）

ROC 曲线


纵轴为TP rate

横轴为FP rate

ROC曲线上的某点对应的横坐标表示：真实为0的样本，模型预测为1的概率（应当越小越好）

ROC曲线上的某点对应的纵坐标表示：真实为1的样本，模型预测为1的概率（应当越大越好）

所以ROC曲线最理想状态是与y轴重合，正常状态下也要是在y=x（随机选择）上方， 否则表示模型更倾向于把对和错预测相反。



AUC

AUC（Area Under roc Curve）是一种用来度量分类模型好坏的一个标准。AUC 就是ROC曲线的阴影部分面积，这部分面积应当与越大越好。

AUC可以理解为，任取一对（正、负）样本，正样本的score大于负样本的score的概率。

### 3. AUC的常用计算方法?

假设总共有  $(m+n)$  个样本，其中正样本  $m$  个，负样本  $n$  个，总共有  $m*n$  个样本对，计数，正样本预测为正样本的概率值大于负样本预测为正样本的概率值记为1，累加计数，然后除以  $(m*n)$  就是AUC的值

### 4. ROC / AUC 的优势?

AUC的计算方法同时考虑了分类器对于正例和负例的分类能力，在样本不平衡的情况下，依然能够对分类器作出合理的评价。

例如：在反欺诈场景，设欺诈类样本为正例，正例占比很少（假设0.1%），如果使用准确率评估，把所有的样本预测为负例，便可以获得**99.9%的准确率**。但是如果使用AUC，把所有样本预测为负例，TPRate和FPRate同时为0（没有Positive），与(0,0) (1,1)连接，得出**AUC的面积为0.5**，成功规避了样本不均匀带来的问题。

### 补充

- P 准确率 =  $\frac{TP}{TP+FP}$  (预测为1的样本，有多少是正确的)
- R 召回率 =  $\frac{TP}{TP+FN}$  (真实为1的样本，有多少预测正确)
- F 值:  $\frac{1}{\frac{1}{2}(\frac{1}{P} + \frac{1}{R})}$  (P值R值的调和平均值)